

随机森林的可解释性可视分析方法研究

杨晔民¹, 张慧军^{1,2}, 张小龙¹

1. 太原理工大学 信息与计算机学院, 山西 晋中 030600

2. 山西传媒学院 融媒技术学院, 山西 晋中 030619

摘要: 由于随机森林算法在很多情况下都以“黑盒”的方式存在, 对于用户而言, 参数调整, 训练甚至最终构建的模型细节是隐蔽的, 这导致了随机森林模型的可解释性非常差, 在一定程度上阻碍了该模型在一些诸如医学诊断、司法、安全领域等需要透明化和可解释需求比较高的领域使用。影响该模型可解释性挑战主要来源于特征选择和数据的随机性。同时随机森林包含许多决策树, 用户很难理解和比较所有决策树的结构和属性。为了解决上述问题, 设计并实现了可视分析系统 FORESTVis, 该系统包括树视图、部分依赖图、t-SNE 投影图、特征视图等多个交互式可视化组件, 借助该系统, 相关研究人员和从业人员可以直观地了解随机森林的基本结构和工作机制, 并协助用户对模型的性能进行评估。使用 Kaggle 公开数据集上进行案例分析, 验证了该方法的可行性和有效性。

关键词: 随机森林; 可视分析; 交互设计; 可解释机器学习

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.1911-0185

Research on Interpretable Visual Analysis Method of Random Forest

YANG Yemin¹, ZHANG Huijun^{1,2}, ZHANG Xiaolong¹

1. College of Information and Computer, Taiyuan University of Technology, Jinzhong, Shanxi 030600, China

2. College of Media Technology, Communication University of Shanxi, Jinzhong, Shanxi 030619, China

Abstract: Random forests are typically applied in a black-box manner where the details of parameters tuning, training and even the final constructed model are hidden from the users in most cases. It leads to a poor model interpretability, which significantly hinders the model from being used in fields that require transparent and explainable predictions, such as medical diagnostics, justice, and security to some extent. The interpretation challenges stem from the randomness of feature selection and data. Furthermore, random forests contain many decision trees, it is difficult or even impossible for users to understand and compare the structures and properties of all decision trees. To tackle these issues, an interactive visual analytics system FORESTVis is designed, it includes tree view, partial dependence plots, t-SNE projection, feature view and other interactive visual components. The researchers and practitioners of the model can intuitively understand the basic structures and working mechanism of random forests and assist users in evaluating the performance of models through interactive exploration. Finally, a case study using the Kaggle public dataset shows that the method is feasible and effective.

Key words: random forests; visual analysis; interaction design; interpretable machine learning

传统上, 随机森林是通过组合弱学习器(决策树)来进行分类和回归的有监督学习模型。由于其具有高性能, 随机森林成为应用广泛的模型之一。虽然随机森林在分类方面具有良好的表现, 但是在实际用于数据分析时会面临诸多挑战。首先, 随机森林模型的“黑盒子”^[1]特性使得模型的构建及预测过程的细节对用户而言都是隐蔽的, 用户只能简单地向随机森林模型导入训练集和输入相关参数, 对于领域专家而言, 并不能理解预测

结果背后的原因。其次, 虽然自动的“黑盒”模型可以让用户免于交互, 认知“减负”, 但是可解释性很差, 阻碍了用户理解和洞察知识。Breiman 等人^[2]认为随机森林的性能排名级别是 A+, 但是可解释性排名级别为 F。因此, 可解释性为“F 级别”的模型无法应用于在对错误预测零容忍或很小程度容忍领域中, 比如在医学诊断中, 机器学习模型常常被用来帮助医生做治疗决策, 当模型预测结果是假阳性或假阴性, 这种错误预测方案对患者

基金项目: 国家自然科学基金(61572344)。

作者简介: 杨晔民(1993—), 男, 硕士研究生, 研究领域为可视分析; 张慧军(1985—), 女, 博士研究生, 研究领域为可视分析; 张小龙(1969—), 通信作者, 男, 博士, 教授, 研究领域为信息可视化、可视分析、人机交互等, E-mail: xiaolong.zhang@gmail.com。

收稿日期: 2019-11-14 **修回日期:** 2020-01-17 **文章编号:** 1002-8331(2021)06-0168-08

来说是致命的。目前有一些机器学习模型可视分析的方法^[3],然而对于随机模型,缺少有效的可视分析手段,使得该模型难以理解。对于随机森林模型,目前流行解释模型的方法是特征的全局重要性。Krause等人^[4]提出了一个可视分析工作流程,利用“实例级解释”来解释单个实例的局部特征相关性度量,帮助数据科学家和领域专家探索、诊断和理解二分类模型做出决策,但该方法对于特征值的变化如何影响预测结果,特征重要性却不能很好的解释。可解释机器学习模型的另一个重要角度是探索该模型的基本结构和工作机制^[5]。对于决策树模型,用户可以通过跟踪根到叶的决策路径来理解基本结构和工作机制,但是随机森林通常包含数百棵独立的决策树,决策路径则更多,用户需要识别更多特定的决策路径,这将是一个非常耗费时间和精力过程,并且增加了用户认知负担。

为了解决上述问题,本文开发了一个交互式的可视分析系统FORESTVis(如图1所示),帮助用户从不同的角度理解随机森林模型,提高随机森林的可解释性。本研究将利用部分依赖图来探索特征重要性,解释特征值的变化对预测值的影响,提高随机森林的可解释性。为了支持本研究,本文使用Kaggle竞赛中泰坦尼克号数据集和MINIST手写数字识别数据集进行案例分析,结果表明该系统可以帮助用户有效地理解、优化随机森林模型。

本工作的主要贡献总结如下:

(1)设计了可视化映射、交互和布局算法并实现了可视分析系统FORESTVis,该系统综合了从数据到视觉呈现的映射算法、多个视图的布局算法和交互方法,

帮助用户从多个角度理解随机森林的基本结构、工作机制以及预测结果。

(2)通过交互式可视化界面,帮助用户分析训练后随机森林的性能,并且提供实例、随机森林模型特征的详细信息,而这些详细信息对于理解、诊断、优化模型非常有用。

(3)该系统可以由较少机器学习专业知识的领域专家使用,用户只需要通过浏览器访问,就可以连接到该系统。

1 相关工作


本章梳理了与该研究相关的一些工作,包括数据实例的理解和异常检测,特征分析,基于树结构的可视化。

1.1 理解数据

理解数据是理解机器学习模型的第一步。在数据工程阶段,数据可视化可以帮助用户探索数据并定性地了解数据的本质。训练模型本质上是从训练数据集中获取知识,很大程度上模型的性能取决于其训练数据集的质量,所以模型开发人员或数据科学家在获取到数据更多知识的情况下,他们可以更好地诊断由于数据的质量或数量问题而导致模型失败的原因。

理解数据主要有三个任务:统计分析、降维和数据集诊断。

统计分析的目的是总结数据集的统计特征,为用户统计理解。最具影响力的可视化设计之一是盒须图,它总结了每个特征的关键统计数据,Potter等人^[6]提出了关于盒须图的可视化设计。然而,机器学习模型的



注: ① 设置视图; ② 性能视图; ③ 特征重要性视图; ④ 部分依赖图(pdp); ⑤ 数据总览视图; ⑥ 数据表,展示数据实例; ⑦ 决策树散点视图; ⑧ 树视图; ⑨ 数据实例; ⑩ 节点链路之间宽度

图1 FORESTVis系统界面示意图

数据集变得越来越复杂,维度越来越高,浏览数百个盒须图并不能完全理解数据集,所以需要降维来理解数据在输入空间中的分布方式。投影是最常用的降维技术之一,可视化的作用是呈现降维的结果,比如使用多维缩放(MDS)将时序数据投影到2D平面上的Time-Curves^[7],在渐进式可视分析(Progressive Visual Analytics)范式中t-分布随机邻域嵌入(t-SNE)的应用^[8]、流行学习、主成分分析(PCA)^[9]等等。

1.2 特征分析

特征选择在机器学习和数据挖掘场景中是非常有用的,它是通过计算特征重要性来筛选有效的特征,即为每个特征分配一个数值来表示对预测结果的影响。

目前评估特征重要性的方法主要有平均精确率减少(MDA)、Boruta、平均不纯度减少(MDI)等。MDA是通过打乱每个特征的特征值顺序,来度量顺序变动对模型的精确率的影响,利用袋外数据错误率来计算特征重要性,而且它适用于任何模型。Boruta是一个“相关”的特征选择算法,检查比随机噪声重要的特征,重复删除比最佳特征差的特征来寻找所有对预测结果有用的特征。

MDI^[10]专门用于基于树结构模型,比如决策树、随机森林等,它表示每个特征对误差的平均减少程度。在树结构中,分裂准则的改进是对分裂变量的重要度量,每次分裂都是针对一个可以使误差最小化的特征(分裂点),误差可以通过计算均方误差、基尼纯度、信息增益等等获得。MDA、MDI、Boruta都可以用于计算特征重要性和预测细节。但是,MDI在随机森林模型中更受欢迎^[10]。然而特征重要性无法显示特征值的变化对预测结果的影响,Krause等人^[11]使用部分依赖图来探索“黑盒”模型,解释模型特征值的变化和预测值之间的关系。

1.3 基于树结构的可视化

本节将着重回顾决策树的可视化。对于决策树的可视化,PaintingClass^[12]使用冰柱图来揭示以感兴趣的节点为中心的局部树结构。构建决策树通常是一个试错过程,需要设置参数、运行算法、评估性能,当用户不了解算法内部工作机制,而且对性能不满意时,需要调整参数,算法再次运行,重复该过程直到用户对构建的决策树满意为止,这非常耗时。人类的模式识别能力可用于提高决策树构建的有效性,用户的积极参与可以帮用户更深入地了解决策树,所以Baobab View^[13]使用节点链接树图和辅助混淆矩阵交互式的显示特征,并且支持交互式的构建和分析决策树。Tree POD^[14]通过探索树构造算法的参数进行采样而生成大量候选树,通过定量和定性方面的可视化提供了对树特征的全面概述,使用基于像素形式(pixel-based)的矩形树图(TreeMap)来帮助用户评估决策树的复杂性和性能,在两个目标之间进行权衡时,Tree POD通过关注帕累托最优(Pareto-optimal)树候选集来提供有效的指导。虽然目前决策树的可视分析系统都是有效的,但不是专门针对随机森林设计的,因为随机森林包含数百棵决策树,随机森林工

作机制中决策路径的结构和属性很难理解,故Zhao等人^[15]设计了iForest工具,它用来可视化特定预测中的决策路径,但是该系统缺陷是对历史数据进行离线预训练和批量计算,不能在线分析随机森林,并且只针对二分类,缺乏多类别、多标签的研究。Munzner等人^[16]提出了新颖的焦点+上下文(Focus+Context)交互技术来可视化有限区域中的树结构,保证树结构的可见性。

总之,由于随机森林的复杂性,目前随机森林算法的可视分析研究相对较少,并且缺乏对随机森林算法全面的分析,可扩展性也较差,不适用于多类别、多标签数据集。本研究是为了增强随机森林模型的可解释性。

2 整体架构

FORESTVis系统是基于Flask和D3.js^[17]搭建的Web可视化应用,系统采用B/S模式,服务器端软件使用Apache,实验中将D3和数据文件部署于Apache服务器端,客户端选用的浏览器是Chrome。用户只需要通过浏览器访问,就可以连接到该系统,并实时链接数据库。如图2所示,FORESTVis系统共4个模块,分别为数据处理及算法模块、数据存储模块、可视化及交互模块。数据处理及算法模块是对数据进行清洗、统计、并加载随机森林算法,并将结果传递到前端可视化模块;数据存储模块负责存储和检索;可视化模块负责向用户提供全面的视觉总结;交互模块支持用户交互式的分析;用户将通过算法的部分结果通过交互传递到数据存储模块。




图2 FORESTVis系统概念图

3 可视化任务分析

本文设计了FORESTVis可视分析系统来帮助随机森林模型的研究人员和从业人员更好地理解该模型及其预测结果。通过观察和采访使用Weka等随机森林模型的人员,确定了需求分析,根据需求开发了系统。FORESTVis是在一个学期内与几个用户协商设计的,他们希望通过可视分析可以更好地理解随机森林模型。与用户的讨论后,希望达到以下分析目标:

(1)能够解释特征和预测之间的关系(T1)。用户需要了解模型的输入和模型的输出预测之间的关系是什么。这有助于用户理解随机森林模型的特征。例如,用户想知道哪些特征对于模型的学习是重要的,以及对预测的影响。而特征重要性可以反映出特征对预测结果

的影响,但是不足以揭示特征值和预测值之间的相关性,用户可能想了解特征值的变化对预测的影响是什么。故本文编码了部分依赖信息,映射了特征变化对预测的影响,同时可以帮助用户进行特征选择,删除不必要的特征。

(2)能够检查决策路径的结构(T2)。随机森林通常包含数百棵决策树,决策路径则更多。决策路径结构包括特征分裂点以及分裂阈值、路径的特征顺序、路径长度等,用过可视化决策路径可以帮助用户理解随机森林底层的工作机制。

(3)能够探索参数的影响(T3)。用户想要探索参数对随机森林的影响。他们希望通过系统直接比较不同的参数对随机森林的影响,他们不仅关心随机森林的性能指标,也关注随机森林的细节。通过尝试可视化不同参数的性能,找到随机森林模型更优的参数。

(4)能够检查模型性能(T4)。所有用户想知道随机森林模型的性能,与用户讨论后,他们认为性能指标可以为他们提供对模型的整体评估,这对于理解模型有很大的帮助。

(5)能够检查训练数据集的分布和检测异常值(T5)。用户想从训练数据集(簇)的分布可以找到数据噪声,协助用户找到相应的数据实例,这对数据的理解和模型性能的改进有很大的帮助。

(6)能够交互式地探索模型(T6)。用户可以交互式探索模型,比如通过探索决策路径来理解随机森林的工作机制,通过探索参数的变化来评估性能,通过探索训练数据集的分布检测异常值等等。

4 可视化及交互设计

本文设计并实现了随机森林模型可视分析方法,包括设置视图、性能视图、特征视图、数据总览视图、树视图、散点图等。

4.1 设置视图

设置视图提供控制随机森林模型的参数,本系统选择了三个主要参数来探索模型,可以帮助用户探索不同的参数对模型性能的影响(T1)。界面左上角为用户提供提供了选择数据集的下拉框,以使用户从后台提取数据,选择分析对象,用户不需要在集成开发环境和可视化界面之间切换,可以直接比较不同模型参数设置对预测结果的影响。单击RUN按钮时,如图3所示,模型开始训练,数据将传输到可视化组件,实时创建不同的视图。




图3 设置视图

4.2 性能视图

FORESTVis系统使用性能视图评估模型。模型的性能是专家关注的焦点,如图4所示,工具使用混淆矩阵来可视化性能,该指标可帮助用户快速了解模型性能(T4)。其中混淆矩阵的列表示预测类别,而行表示实际类别,它提供了一种非常方便的方法来比较预测标签与实际标签,机器学习研究人员和从业人员可以很容易地理解这些标签,视图下面显示了训练集和测试集的AUC值。




图4 性能视图

4.3 特征视图

如图5所示,特征视图由直方图和部分依赖图组成,用于探索特征与预测结果的关系。随机森林模型是反映输入特征和输出预测的映射关系,所以探索特征与预测结果的关系可以帮助用户分析模型如何从训练数据集学习,从而更好地理解随机森林模型(T1)。图5上面的图表示MNIST手写数据集中数字5类别的特征重要性,可以帮助用户了解哪些特征对于模型是重要的,其中标注(a)处可以将特征重要性按升序或者降序排列。图5下面的图是特征F28的部分依赖图,使用折线图表示部分依赖图,它显示的是一个或两个特征对模型预测结果的边际效应,即模型预测与“目标特征”之间的依赖关系,它是一种“事后可解释性”(post-hoc interpretable)方法,虽然没有阐明预测模型运作的内部机制,但是显示了模型在响应输入变化时的行为方式,可以帮助




图5 特征视图

数据科学家识别模型的缺陷,并向利益相关者解释他们的模型,比如信用卡申请者和医疗患者等。在部分依赖图中(pdp), x 轴表示目标特征值,当保持所有其他特征值不变时, y 轴表示模型预测的平均值。对于部分依赖信息,令特征 $x = \{x_1, x_2, \dots, x_p\}$, 随机森林模型预测函数为 $f(x)$, z_s 为用户感兴趣的特征, z_c 为 z_s 的补集 ($x - \{z_s\}$), 那么 z_s 的部分依赖函数定义为:

$$f_{x_s} = E_{x_c}[f(x_s, x_c)] = \int f(x_s, x_c) dP(x_c) \quad (1)$$

$$f_s(z_s) = E[f(z_s, z_c)] = \int f(z_s, z_c) p_c(z_c) dz_c \quad (2)$$

$$p_c(z_c) = \int p(x) dz_s \quad (3)$$

$p_c(z_c)$ 为 z_c 边缘概率密度。

实际上,不可能对 z_c 的所有可能值进行积分,因此通常将上述公式估计为:

$$\bar{f}_s(z_s) = \frac{1}{n} \sum_{i=1}^n f(z_s, z_{i,c}) \quad (4)$$

其中, $z_{i,c} (i=1, 2, \dots, n)$ 是 z_c 在训练样本中的值。

4.4 数据总览视图

数据总览视图主要由散点图、数据表构成,反映数据样本集群和异常值情况。对于多维数据的可视化通常使用平行坐标图或者降维技术,但是对于高维度数据集使用平行坐标图时空间占有率太大,容易引起视觉混淆,而降维方法可以展示训练数据集良好可扩展性。为了观察高维数据向量在特征空间的分布情况,希望能把高维数据投影到二维空间上,直观地理解数据的结构,并通过视觉直观验证效果。选择使用 t-SNE 算法将高维特征向量投影到二维平面上,形成散点图。如图6上面散点图中每个点代表一个数据实例,颜色代表数据类别。




图6 数据实例总览视图

同时该散点图也支持缩放和平移技术,帮助用户专注于视图的特定区域,将鼠标放在所选散点图上,将展示这个数据实例的图像,而且用户可以通过双击散点图来删除数据实例。如图6的下图为一个数据表,可以允许用户浏览整个训练数据集,由于性能和数据实例已经被证明是不可分离的,所以通过数据表允许用户查看某条数据实例的异常情况(T5)。当特征数量增加时,用户可以使用滚动条检查它们,不会限制数据集中的总特征数量。

4.5 树视图

随机森林由很多决策树构成,为了直观地可视化决策树结构,FORESTVis系统使用节点链接图来表示决策树结构,因为它具有直观性而且用户对它很熟悉。但是,当决策树的深度较大,导致没有足够的空间来表示固定区域的所有节点,因此使用焦点+上下文技术,允许用户拖动、缩放、平移、折叠树。如图7所示,节点之间链路的宽度用于表示该分支的数据实例的数量,当选定实例时,其他实例路径为灰色,图7右侧则显示决策的路径。决策路径结构可以帮助用户更好地理解随机森林模型底层的工作机制(T2)。本系统采用基于像素的可视化技术来编码预测类别,每一个决策路径将会输出一个类别。




图7 树视图

4.6 决策树散点视图

FORESTVis系统提供决策路径引导用户探索随机森林的基本结构和工作机制。随机森林通常包含数百棵独立的决策树,决策路径则更多,用户需要识别更多特定的决策路径。如果可视化每棵树,空间占有率太大,容易引起视觉混淆。故将利用每棵决策树的相似性采用 t-SNE 投影,如图8所示,将决策树投影到二维平面上,散点图中每个点代表一棵决策树。t-分布随机邻域嵌入是一种非线性降维算法,适用于高维数据降到2维或者3维,并进行可视化。

可视化步骤如下:

首先通过将数据点之间的高维欧氏距离转换为表示相似性的条件概率,条件概率 p_{ji} 定义为:

$$p_{ji} = \frac{\exp(-\|x_j - x_i\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_k - x_i\|^2 / 2\sigma_i^2)} \quad (1)$$




图8 决策树散点视图

$$p_{ij} = \frac{p_{ji} + p_{ij}}{2n} \quad (2)$$

p_{ji} 表示点 x_j 出现在点 x_i 附近的条件概率, σ_i 为对应高斯方差, x_i, x_j 为高维空间的任意两点, p_{ij} 为任意高维空间两点的相似性度量局部对称联合概率分布。由于高维空间中的点映射到低维空间后过于聚集, t-SNE 定义了概率分布函数 q_{ij} 来度量低维空间点的相似性。定义如下:

$$q_{ij} = \frac{(1 + \|y_i - y_j\|_2^2)^{-1}}{\sum_{k \neq l} (1 + \|y_l - y_k\|_2^2)^{-1}} \quad (3)$$

其中, y_i 和 y_j 为低维空间点对, $\|y_i - y_j\|_2$ 则表示低维空间两点的距离, 而且用自由度为 1 的 t 分布函数代替了高斯分布, 从而避免了“拥挤问题”。

4.7 交互过程

FORESTVis 系统的交互设计遵循的是 Shneiderman^[18] 提出的大规模数据可视化交互范式:“首先给出概览, 通过缩放和筛选, 根据需要展示细节”。上述各个视图之间在数据选择、参数设置之后具有友好联动性且数据是共享的。为了保持用户对各个视图的感知, 将所有的视图按图 1 所示放置, 将所有视图放置在一个屏幕, 理解各种交互操作带来的影响, 从而帮助用户从各个角度理解随机森林模型(T6)。如图 3 参数设置视图所示, FORESTVis 系统也支持实时修改参数重计算。用户探索模型阶段, 用户首先在设置视图选择模型参数, 并依据性能视图的响应确定最佳参数。分析数据阶段, 用户在数据总览视图(图 6)查看数据的分布以及异常值, 经过筛选, 查看感兴趣的数据或者异常数据。理解模型阶段, 用户在特征视图中可以选择感兴趣的特征, 观察特征重要性以及特征对预测结果的影响。在决策树散点视图中, 用户可以选择自己感兴趣的决策树, 在树视图对该路径进一步探索和标记, 且支持请求式的更新操作。

5 案例分析

在本章中, 通过 Kaggle 竞赛中的两个数据集来验证 FORESTVis 系统的有效性。在开发了 FORESTVis 系统之后, 让用户探索系统, 他们可以使用 FORESTVis 系统在线探索随机森林算法。在一个月后, 收集了一些用户的反馈。用户是硕士研究生一年级的学生, 他们是机器学习的初学者, 希望通过 FORESTVis 来理解随机森林算法的基本结构、工作机制以及预测结果。

5.1 案例分析 1

用户 A 希望通过 FORESTVis 系统理解并诊断随机森林算法。用户 A 选择了 MNIST 手写数据集, 在设置视图中设置了三个参数, max_features 设置为 10, n_estimators 为 100, min_sample_leaf 为 50, 运行算法。然后用户 A 通过观察每个类的表现即每个类的混淆情况, 发现数字 2 和数字 3 的相交的矩形框颜色最深(图 1 ⑥), 故认为数字 2 和数字 3 混淆程度最大。为了找到可能解释的原因, 用户 A 把注意力转到了特征视图(图 1 ③、1 ①), 用户 A 首先选择了混淆矩阵上颜色最浅即混淆程度最小的数字 5 的类。通过点击特征视图中的排序功能, 发现 F28 特征重要性排在第一位, 并且与其他特征重要性的差距很明显(图 9(a))。用户 A 认为特征 F28 在随机森林分类器中对数字 5 和其他数字的分类中具有非常重要的作用。为了探索特征 F28 的变化如何影响预测值, 点击特征视图 F28(图 1 ③), 特征 F28 颜色变黄, 观察部分依赖图(图 1 ④), 发现随着特征值 F28 的变大, 预测值呈负相关。用户 A 为了验证特征 F28 的重要性, 通过点击决策树散点视图中的散点后, 在决策树视图发现绝大部分特征 F28 位于树的顶层, 并且观察了决策树的第一层到第二层的节点链路之间宽度(图 1 ⑥), 发现这一层把大部分数字 5 的实例与其他实例分离, 这解释了特征 F28 对数字 5 具有很好的分类效果。用户 A 为了寻找数字 2 和数字 3 容易混淆的原因, 他选择观察了数字 2 和数字 3 的特征重要性排序, 如图 9(b), 9(c) 所示, 发现数字 2 和 3 两个类别的特征重要性差距不明显, 分布均匀, 这解释了数字 2 和 3 不易区分。故用户 A 认为没有一个特征可以把数字 2 和 3 的实例与其他实例明显地分开。由于性能的评估可以帮助用户理解随机森林算法, 故用户 A 打算查看数据实例的分布以及算法的 AUC 值了解随机森林。用户 A 在观察实例之间的关系时, 发现了一些异常值, 如图 1 ⑤ 所示, 数字 9 被分到 5 的集群(簇)中, 数字 2 被分到了 3 的集群(簇)





图9 数字类别 5、2、3 的特征重要性

中等等(图1 ⑤ 红色方框),点击散点图查看数据实例,如图1 ⑥,这种错误的情况很容易被错误分类,因为原数据中数字5和数字6比较相似,这些数据可以通过增加像素的分辨率来修复这些误差,故用户A通过重新处理数据,增加其输入分辨率,通过双击移除这些异常值并重新加载FORESTVis,发现Training AUC由0.890增加到0.912,且TestingAUC由0.880增加到0.930,即提高了模型的性能。

5.2 案例分析2


用户B希望通过FORESTVis系统直观地理解随机森林。首先他想了解在泰坦尼克号沉船事件中哪些人群存活下来了,他们的特征是什么,随机森林算法是如何预测存活率的。在运行FORESTVis系统前,用户B首先对训练集中891个乘客的数据进行特征工程处理,最终生成了七个特征,分别为客舱等级(Pclass)、性别(Gender)、年龄(Age)、船票价格(Fare)、登船港口(Embarked)、乘客姓名头衔(Title)、家庭人数是否一个人(IsAlone)。Survival是存活状态,阳性(Survival=1)表示该乘客在沉船事件中存活,阴性(Survival=0)表示该乘客丧失,图10 ⑦ 是该训练集的数据实例。如图10 ⑧ 所示,用户B将清洗后的数据加载到FORESTVis系统中,他首先观察特征视图中的特征重要性排序,查看那些特征在模型预测中更重要,如图10 ⑨ 所示,通过点击排序功能发现性别排在了第一位,故认为所有特征中性别是随机森林算法预测最重要的。接着用户B希望了解性别如何影响随机森林模型预测结果,所以将注意力转向了部分依赖图(图10 ⑩),通过点击特征重要性

视图中的性别(Gender)特征,在部分依赖图中发现当性别是女性(Gender=1)时,预测分数即生存率较高,男性(Gender=0)的生存率较低,表明了女性在泰坦尼克号沉船事件中存活率比男性高,解释了随机森林模型的学习模式和女性乘客更有可能在泰坦尼克号沉船中存活的事实相符^[9]。为了验证性别对随机森林模型预测的重要性,用户B在决策树散点视图(图10 ⑪)中选择了一部分散点加载到树视图图中发现,大部分树中顶层的特征是性别(图10 ⑫),这解释了第一个分列点的基尼系数最小的原因,所以用户B认为特征性别对模型的预测非常重要。用户B希望进一步了解特征值的变化如何影响预测结果,于是选择观察船票价格和年龄的变化对预测的影响,如图11 ⑬ 所示,船票价格为25左右时,曲线是非常的陡峭,即25是一个临界点(阈值),当船票价格高于25时存活率突然增大。当船票价格大于25时,这些乘客乘坐的是头等舱,船票价格低于25时,船票是经济舱,故用户B认为乘客的船票价格大于25时其生存率更高,即随着船票价格(特征值)的增加,生存的几率(预测值)有增加的趋势。如图11 ⑭ 年龄视图,用户想探索年龄的变化对预测值的影响,发现年龄在30岁之前,乘客的生存率较高,并且随着年龄(特征值)的增加,存活率(预测值)逐渐降低。接着用户B希望通过查看性能视图(图10 ⑮)评估随机森林算法的性能,首先观察了数据总览视图实例的分布,如图10 ⑯ 所示,发现了一些数据噪声,通过剔除这些数据并重新加载FORESTVis系统,发现Training AUC由0.860增加到0.892,且TestingAUC由0.860增加到0.911。



注: ① 设置视图; ② 性能视图; ③ 特征重要性视图; ④ 特征性别的部分依赖图; ⑤ 数据总览视图; ⑥ 数据表, 展示泰坦尼克数据集实例; ⑦ 决策树散点图; ⑧ 树视图; ⑨ 异常数据; ⑩ 决策树中最顶层的特征

图10 FORESTVis加载泰坦尼克数据集解释随机森林



注: ① 为最陡峭曲线上上升趋势

图11 船票价格和年龄的特征视图

6 总结及未来工作

本文设计了一个交互式多视图(包括:树图视图、部分依赖图、t-SNE投影散点视图、特征视图、其他辅助信息视图)的可视分析系统FORESTVis,帮助机器学习专家和领域专家更好地理解与使用随机森林模型。同时,该系统支持在线分析,实时修改参数重计算,丰富的视图形式和交互手段,便于用户交互式探索、理解模型,而且简单易用。

未来将从以下几个方面作进一步改进和研究。首先计划向公众提供FORESTVis系统,并根据收集的反馈进一步改进系统。其次,增加系统扩展性,计划在线支持更多的模型,如神经网络、梯度提升树等。

参考文献:

- [1] PALCZEWSKA A, PALCZEWSKI J, ROBINSON R M, et al. Interpreting random forest models using a feature contribution method[C]//IEEE 14th International Conference on Information Reuse & Integration (IRI), 2013: 112-119.
- [2] LEO B. Statistical modeling: the two cultures (with comments and a rejoinder by the author)[J]. Statistical Science, 2001, 16(3): 199-231.
- [3] 任磊, 杜一, 马帅, 等. 大数据可视分析综述[J]. 软件学报, 2014(9): 1909-1936.
- [4] KRAUSE J, DASGUPTA A, SWARTZ J, et al. A workflow for visual diagnostics of binary classifiers using instance-level explanations[C]//IEEE Conference on Visual Analytics Science and Technology, 2017: 162-172.
- [5] LIPTON Z C. The mythos of model interpretability[J]. Communications of the ACM, 2016, 61(10).
- [6] POTTER K, KNISS J, RIESENFELD R, et al. Visualizing summary statistics and uncertainty[J]. Computer Graphics Forum, 2010, 29(3): 823-832.
- [7] BACH B, SHI Conglei, HEULOT N, et al. Time curves: folding time to visualize patterns of temporal evolution in data[J]. IEEE Transactions on Visualization Computer Graphics, 2016, 22(1): 559-568.
- [8] PEZZOTTI N, LELIEVELDT B P F, VAN DER MAATEN L, et al. Approximated and user steerable tSNE for progressive visual analytics[J]. IEEE Transactions on Visualization Computer Graphics, 2017, 23(7): 1739-1752.
- [9] 方正, 曹铁勇, 郑云飞, 等. 高效深度特征提取及其在显著性检测中的应用[J]. 计算机辅助设计与图形学学报, 2019, 31(2): 144-151.
- [10] LOUPPE G, WEHENKEL L, SUTERA A, et al. Understanding variable importances in forests of randomized trees[J]. IEEE Transactions on Visualization & Computer Graphics, 2013, 19(12): 431-439.
- [11] KRAUSE J, PERER A, NG K. Interacting with predictions: visual inspection of black-box machine learning models[C]//2016 CHI Conference, 2016.
- [12] TEOH S T, MA K L. Painting class: interactive construction, visualization and exploration of decision trees[C]//Proceedings of the Ninth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Washington, DC, USA, 2003: 667-672.
- [13] VAN DEN ELZEN S, VAN WIJK J. Baobabview: interactive construction and analysis of decision trees[C]//IEEE Conference on Visual Analytics Science and Technology, 2011: 151-160.
- [14] MÜHLBACHER T, LINHARDT L, MÖLLER T, et al. TreePOD: sensitivity-aware selection of pareto-optimal decision trees[J]. IEEE Transactions on Visualization and Computer Graphics, 2018, 24(12): 174-183.
- [15] ZHAO X, WU Y, LEE D L, et al. iForest: interpreting random forests via visual analytics[J]. IEEE Transactions on Visualization and Computer Graphics, 2019, 25(1): 407-416.
- [16] MUNZNER T, GUIMBRETIERE F, TASIRAN S, et al. TreeJuxtaposer: scalable tree comparison using focus + context with guaranteed visibility[J]. ACM Transactions on Graphics, 2003, 22(3): 453-462.
- [17] 吕之华. 精通D3.js: 交互式数据可视化高级编程[M]. 北京: 电子工业出版社, 2005: 1-2.
- [18] SHNEIDERMAN B. The eyes have it: a task by data type taxonomy for information visualization[C]//Proceedings of IEEE Symposium on Visual Languages, 2003: 364-371.
- [19] HALL W. Social class and survival on the S.S. Titanic[J]. Social Science & Medicine, 1986, 22(6): 687-690.